14.09.2026

Capex vs. Opex

Einleitung

Wenn Unternehmen über den Einsatz von Cloud-Diensten entscheiden, geht es nicht nur um technische Eignung, sondern immer auch um wirtschaftliche und organisatorische Konsequenzen.

Aus Unternehmensperspektive stellen sich Fragen wie:

- Was kostet uns das wirklich?
- Wer trägt die Verantwortung, wenn etwas ausfällt?
- Was passiert mit unseren Daten?
- Und wie abhängig machen wir uns von einem externen Anbieter?

Einleitung

Diese Fragen sind in der AP2 ausdrücklich prüfungsrelevant.

Die IHK erwartet, dass Azubis Cloud-Entscheidungen nicht nur technisch, sondern auch betriebswirtschaftlich einordnen können.

Der wichtigste betriebswirtschaftliche Begriff ist die Unterscheidung zwischen Capex und Opex.

Capex

Capex steht für Capital Expenditure, also Investitionsausgaben für langlebige Wirtschaftsgüter wie Server, Netzwerkhardware oder Rechenzentrumsinfrastruktur.

Diese Ausgaben werden aktiviert, über mehrere Jahre abgeschrieben und belasten den Cashflow zum Zeitpunkt der Anschaffung erheblich.

Opex

Opex steht für Operational Expenditure, also laufende Betriebsausgaben wie Miete, Strom oder eben Cloud-Abonnements.

Opex-Ausgaben fallen regelmäßig und planbar an, belasten aber nicht das Anlagevermögen.

Von Capex zu Opex

Der Wechsel von einer eigenen IT-Infrastruktur zu Cloud-Diensten ist im Kern eine Verschiebung von Capex zu Opex.

Statt einmalig große Summen in Hardware zu investieren, zahlt das Unternehmen monatliche Nutzungsgebühren.

Das hat weitreichende Konsequenzen für Budgetplanung, Bilanz und Flexibilität.

Vorteile

Kosten

Keine hohen Anfangsinvestitionen, keine Abschreibungen, keine Kosten für Hardware-Erneuerung alle fünf bis sieben Jahre. Stattdessen planbare monatliche Kosten, die direkt an die tatsächliche Nutzung gekoppelt sind.

Skalierbarkeit

Wächst das Unternehmen, werden einfach mehr Ressourcen hinzu gebucht. Ohne Beschaffungsprozess, ohne Lieferzeiten, ohne Kapazitätsplanung mit großem Sicherheitspuffer.

Vorteile

Verlagerung von Verwaltungsaufwand

Betrieb, Wartung, Updates und Sicherheit der Infrastruktur übernimmt der Anbieter. Das entlastet die interne IT und ermöglicht es ihr, sich auf wertschöpfendere Aufgaben zu konzentrieren.

Sicherheit

Schließlich bieten große Cloud-Anbieter eine Verfügbarkeit und Ausfallsicherheit, die die meisten mittelständischen Unternehmen mit eigener Infrastruktur nicht erreichen könnten.

Nachteile

Abhängigkeit vom Anbieter (Vendor Lock-in)

Wer seine Infrastruktur, Anwendungen und Daten tief in eine Cloud-Plattform integriert hat, kann nur mit erheblichem Aufwand zu einem anderen Anbieter wechseln.

Das schwächt die Verhandlungsposition des Unternehmens bei Preiserhöhungen erheblich.

Nachteile

Eingeschränkte Kontrolle

Das Unternehmen hat keinen direkten Zugriff auf die physische Infrastruktur und ist auf die Sicherheits- und Datenschutzpraktiken des Anbieters angewiesen.

Transparenz

Bei Public Cloud ist zudem der Speicherort der Daten oft nicht vollständig transparent und das kann bei sensiblen Daten zu DSGVO-Problemen führen.

Kosten

Langfristig können die laufenden Opex-Kosten außerdem die einmaligen Capex-Kosten einer eigenen Infrastruktur übersteigen. Cloud ist nicht automatisch günstiger, sondern anders strukturiert.

Datenschutz und Compliance

Datenschutz ist aus Unternehmensperspektive kein weicher Faktor, sondern ein harter rechtlicher Rahmen.

Die DSGVO schreibt vor, dass personenbezogene Daten von EU-Bürgern grundsätzlich nur in Ländern gespeichert werden dürfen, die ein angemessenes Datenschutzniveau gewährleisten.

Prüfungsrelevante Einordnung



In der AP2 taucht Capex vs. Opex typischerweise in Aufgaben auf, die eine Investitionsentscheidung oder einen Kostenvergleich verlangen.

Die erwartete Antwort zeigt, dass der Azubi den Unterschied nicht nur benennen, sondern im Kontext einer Unternehmensentscheidung anwenden kann.

Ein typisches Szenario:
"Ein mittelständisches Unternehmen überlegt, seine Server-Infrastruktur durch eine Public-Cloud-Lösung zu ersetzen. Nennen Sie je zwei wirtschaftliche Vorteile und Nachteile."

Prüfungsrelevante Einordnung



Die Antwort sollte folgendes enthalten:

- ⊕ Capex-zu-Opex-Verschiebung
- ⊕ Skalierbarkeit
- ⊕ Geringeren Verwaltungsaufwand
- ⊖ Vendor Lock-in
- ⊖ Langfristige Kostenstruktur
- ⊖ Datenschutzrisiken

SLAs, Verfügbarkeitsklassen

Was ist ein SLA?

Ein Service Level Agreement, kurz SLA, ist eine vertragliche Vereinbarung zwischen einem Dienstleister und seinem Kunden, die definiert, welche Qualität und Verfügbarkeit ein Dienst mindestens erfüllen muss.

SLAs sind kein technisches Dokument, sondern ein rechtlich bindendes Instrument: sie legen fest, was der Kunde erwarten darf, wie Ausfälle gemessen werden, und welche Konsequenzen es hat, wenn der Anbieter die vereinbarten Werte nicht einhält.

Was ist ein SLA?

Typische Inhalte eines SLA sind:

- Garantierte Verfügbarkeit in Prozent
- Reaktionszeiten bei Störungen
- Wiederherstellungszeiten
- Vereinbarte Konventionalstrafen bei Unterschreitung

Für Unternehmen, die Cloud-Dienste oder externe IT-Dienstleistungen nutzen, ist das SLA das zentrale Instrument zur Absicherung ihrer Anforderungen.

„Verfügbarkeit in Prozent“

Verfügbarkeit wird in SLAs als Prozentwert angegeben.

Was bedeutet es konkret, wenn ein Anbieter 99,9% Verfügbarkeit zusichert?

Um das zu verstehen, muss man den Prozentwert in tatsächliche Ausfallzeit umrechnen.

Ein Jahr hat 8.760 Stunden. 99,9% Verfügbarkeit bedeutet, dass 0,1% dieser Zeit als Ausfall akzeptiert wird. Das sind 8,76 Stunden Ausfall pro Jahr.

Das klingt wenig, kann aber für einen Online-Shop oder ein produktionskritisches System erhebliche Konsequenzen haben.

Verfügbarkeitsklassen

In der Praxis haben sich bestimmte Verfügbarkeitsklassen etabliert, die oft als "Nines" bezeichnet werden (also nach der Anzahl der Neunen).

- 99% Verfügbarkeit entspricht einer maximalen Ausfallzeit von etwa 87,6 Stunden/Jahr (also fast vier Tagen). Das ist für die meisten produktiven Systeme inakzeptabel.
- 99,9% („drei Neunen“) entsprechen etwa 8,76 Stunden/Jahr. Das ist ein typischer Wert für Standard-Cloud-Dienste.
- 99,99% („vier Neunen“) entsprechen etwa 52 Minuten/Jahr und gilt als hohe Verfügbarkeit.
- 99,999% („fünf Neunen“) entsprechen etwa 5 Minuten/Jahr und sind der Maßstab für hochkritische Systeme wie Finanzinfrastruktur oder Notfallkommunikation.

Jede weitere Neun ist technisch deutlich aufwändiger und teurer zu erreichen als die vorherige.

Was SLAs nicht regeln

Ein häufiger Fehler in der Praxis ist die Annahme, ein SLA mit hohem Verfügbarkeitswert bedeute automatisch, dass der Dienst nie ausfällt. Das stimmt nicht.

Ein SLA definiert eine akzeptable Ausfallzeit und kein Ausfallverbot.

Was SLAs nicht regeln

Außerdem enthalten SLAs fast immer Ausnahmen:

- geplante Wartungsfenster werden oft nicht als Ausfall gezählt
- höhere Gewalt ist ausgeschlossen
- die Messmethode für Verfügbarkeit ist oft zugunsten des Anbieters definiert

Wichtig ist auch die Frage, was bei Unterschreitung des SLA passiert:

Typischerweise gibt es Gutschriften auf die nächste Rechnung, aber keinen Ersatz für entstandene Geschäftsschäden.

Was SLAs nicht regeln

Ein SLA ist also ein Qualitätsversprechen mit begrenzter Haftung, aber kein Rundum-Schutz.

Prüfungsrelevante Einordnung



In der AP2 kommen SLA-Aufgaben in zwei Varianten vor.

Die erste ist eine Rechenaufgabe:

„Ein Anbieter garantiert 99,95% Verfügbarkeit — wie viele Stunden Ausfall sind pro Jahr maximal zulässig?“

Die zweite ist eine Bewertungsaufgabe:

„Ein Unternehmen betreibt einen Online-Shop, der rund um die Uhr erreichbar sein muss. Der Anbieter bietet ein SLA mit 99,9% an. Ist das ausreichend?“

Prüfungsrelevante Einordnung



Die erwartete Antwort rechnet die erlaubte Ausfallzeit aus, setzt sie in Relation zum Geschäftsmodell (bei einem Online-Shop bedeuten 8,76 Stunden Ausfall pro Jahr potenziell erheblichen Umsatzverlust) und empfiehlt gegebenenfalls ein höheres SLA-Level oder eigene Redundanzmaßnahmen.

Wer sowohl rechnen als auch einordnen kann, hat die Aufgabe vollständig beantwortet.

Skalierbarkeit, Elastizität

Einleitung

Einer der meistgenannten Vorteile von Cloud-Infrastrukturen ist Skalierbarkeit, also die Fähigkeit, Ressourcen an veränderte Anforderungen anzupassen.

Aber Skalierbarkeit ist kein Cloud-exklusives Konzept, sondern ein grundlegendes Prinzip der IT-Infrastrukturplanung.

Der Unterschied zur klassischen On-Premises-Welt liegt in der Geschwindigkeit und Flexibilität, mit der skaliert werden kann.

Einleitung

In der Cloud dauert das Hinzufügen von Ressourcen Minuten statt Wochen.

Für die AP2 sind drei Begriffe sauber zu unterscheiden:

- Vertikale Skalierung
- Horizontale Skalierung
- Elastizität

Sie beschreiben unterschiedliche Strategien, auf veränderte Last zu reagieren und haben jeweils eigene Vor- und Nachteile.

Vertikale Skalierung: Scale Up

Vertikale Skalierung bedeutet, einen vorhandenen Server leistungsfähiger zu machen: also mehr CPU-Kerne, mehr RAM oder schnelleren Speicher hinzuzufügen.

Das System bleibt dasselbe, es wird nur stärker.

In der physischen Welt bedeutet das einen Hardware-Austausch mit Downtime.

In der virtualisierten oder Cloud-Umgebung kann es deutlich schneller gehen: einer VM werden einfach mehr vCPUs oder RAM zugewiesen.

Vertikale Skalierung: Scale Up

Vorteil

Einfachheit: Die Anwendung muss nicht angepasst werden, es gibt weiterhin nur ein System, und die Verwaltung bleibt unkompliziert.

Nachteil

Die natürliche Grenze: irgendwann ist die maximale Ausbaustufe einer Maschine erreicht, und darüber hinaus ist vertikale Skalierung nicht möglich.

Horizontale Skalierung: Scale Out

Horizontale Skalierung bedeutet, statt einen Server größer zu machen, weitere Server hinzuzufügen und die Last auf mehrere Systeme zu verteilen.

Statt eines leistungsstarken Servers betreibt man viele gleichartige Server, die gemeinsam die Arbeit erledigen.

Das erfordert in der Regel einen vorgelagerten Loadbalancer, der eingehende Anfragen gleichmäßig auf die verfügbaren Server verteilt.

Horizontale Skalierung: Scale Out

Vorteil

Die theoretisch unbegrenzte Skalierbarkeit: weitere Server können jederzeit hinzugefügt werden, ohne das Gesamtsystem anzuhalten.

Nachteil

Die höhere Komplexität: Die Anwendung muss für den Betrieb auf mehreren Instanzen ausgelegt sein, Sitzungsdaten müssen zentral verwaltet werden, und die Infrastruktur wird aufwändiger zu betreiben.

Vergleich

Beide Ansätze haben ihren Platz. Die Wahl hängt von der Anwendungsarchitektur und den Anforderungen ab.

- Vertikale Skalierung ist einfacher umzusetzen und eignet sich gut für Anwendungen, die nicht für den Parallelbetrieb auf mehreren Instanzen ausgelegt sind, etwa klassische Datenbanksysteme oder monolithische Anwendungen.
- Horizontale Skalierung ist aufwändiger in der Umsetzung, aber langfristig mächtiger und resilienter: fällt ein Server aus, übernehmen die übrigen.

Vergleich

Moderne Cloud-Architekturen setzen daher bevorzugt auf horizontale Skalierung, weil sie sowohl Skalierbarkeit als auch Ausfallsicherheit in einem Ansatz vereint.

In der Praxis werden beide Ansätze oft kombiniert: zunächst wird vertikal skaliert bis zu einem sinnvollen Limit, danach horizontal.

Elastizität: Skalierung in beide Richtungen

Elastizität

Während Skalierbarkeit beschreibt, dass ein System wachsen kann, beschreibt Elastizität die Fähigkeit, Ressourcen je nach aktueller Last dynamisch und automatisch sowohl hinzuzufügen als auch wieder freizugeben.

Elastizität: Skalierung in beide Richtungen

Ein elastisches System skaliert bei steigender Nachfrage automatisch hoch und bei sinkender Nachfrage automatisch wieder herunter.

Das ist wirtschaftlich entscheidend: Es wird nur das bezahlt, was tatsächlich genutzt wird.

Ein klassisches Beispiel ist ein Online-Shop, der im normalen Betrieb zehn Server-Instanzen benötigt, in der Weihnachtszeit aber kurzfristig auf fünfzig hochskaliert und danach automatisch wieder auf zehn zurückgeht.

Prüfungsrelevante Einordnung



In der AP2 werden diese drei Begriffe häufig in Kombination mit Cloud-Szenarien geprüft.

Eine typische Aufgabe beschreibt ein Unternehmen mit stark schwankender Last und fragt, welche Skalierungsstrategie empfohlen wird und warum.

Prüfungsrelevante Einordnung



Die erwartete Antwort unterscheidet vertikale und horizontale Skalierung, erklärt den Unterschied zur Elastizität und begründet die Empfehlung anhand des Szenarios.

Wichtig ist dabei die saubere Abgrenzung.

Skalierbarkeit ist eine Eigenschaft des Systems: es kann wachsen.

Elastizität ist eine Eigenschaft des Betriebs: es wächst und schrumpft automatisch nach Bedarf.

Wer diese Nuance in der Prüfungsantwort zeigt, hebt sich von einer reinen Begriffsdefinition ab und demonstriert echtes Verständnis.

Themenblock 3
Speicherarchitekturen

Überblick

- DAS, NAS, SAN: Unterschiede und Protokolle (NFS, SMB, usw.)
- RAID-Level (0, 1, 5, 6, 10): Nutzkapazität berechnen und Ausfallsicherheit begründen
- Tiered Storage, Caching-Konzepte
- Backup-Strategien: Voll vs. Differenziell vs. Inkrementell
- RTO (Recovery Time Objective) und RPO (Recovery Point Objective)

Typische Prüfungslogik:

"Ein Unternehmen hat 4 Festplatten à 4 TB. Vergleichen Sie RAID 5 und RAID 10 hinsichtlich Nutzkapazität, Ausfallsicherheit und Leseleistung."

DAS / NAS / SAN

Einleitung

Wenn ein Unternehmen Speicherplatz für Server, Anwendungen oder Nutzer bereitstellen will, gibt es grundsätzlich drei architektonische Ansätze:

- DAS — Direct Attached Storage
- NAS — Network Attached Storage
- SAN — Storage Area Network

Sie unterscheiden sich darin, wie der Speicher physisch angebunden ist, über welches Protokoll auf ihn zugegriffen wird und wie viele Systeme ihn gleichzeitig nutzen können.

Einleitung

Diese Unterscheidung ist nicht nur theoretisch, sondern hat direkte Konsequenzen für Performance, Skalierbarkeit und Einsatzzweck.

Für die AP2 muss man alle drei Architekturen benennen, ihre Funktionsweise erklären und für ein gegebenes Szenario die passende auswählen können.

DAS: Direct Attached Storage

DAS ist die einfachste Form der Speicheranbindung.

Der Speicher ist direkt mit einem einzelnen Server oder Computer verbunden (typischerweise über SATA, SAS oder USB).

Es gibt keine Netzwerkkomponente zwischen Server und Speicher.

DAS: Direct Attached Storage

- Der größte Vorteil ist die Geschwindigkeit: Da keine Netzwerklatenz dazwischenliegt, ist der Zugriff sehr schnell. Auch die Kosten sind gering, und die Einrichtung ist simpel.
- Der entscheidende Nachteil ist, dass der Speicher exklusiv an genau dieses eine System gebunden ist und andere Server können nicht darauf zugreifen.

DAS eignet sich für einzelne Server mit hohem Performance-Bedarf, etwa lokale Datenbankspeicher, oder für kleine Umgebungen, in denen kein gemeinsamer Speicherzugriff benötigt wird.

NAS: Network Attached Storage

NAS ist ein eigenständiges Speichersystem, das über ein normales Netzwerk angebunden wird und Dateien für mehrere Clients gleichzeitig bereitstellt.

Ein NAS-System ist im Kern ein spezialisierter Server, der Speicherplatz über Dateisystemprotokolle freigibt.

NAS: Network Attached Storage

Die zwei zentralen Protokolle dabei sind SMB (Server Message Block, vor allem im Windows-Umfeld verbreitet) und NFS (Network File System), vor allem im Linux/Unix-Umfeld verbreitet.

Beide Protokolle arbeiten auf Dateiebene: Der Client sieht Ordner und Dateien, nicht die zugrundeliegende Festplattenstruktur.

NAS ist einfach einzurichten, kostengünstig im Vergleich zu SAN, und ideal für Datei-Sharing zwischen mehreren Nutzern oder Servern (etwa zentrale Ablagen für Dokumente, Profile oder gemeinsam genutzte Projektdateien).

SAN: Storage Area Network

Ein SAN ist ein eigenes, dediziertes Hochgeschwindigkeitsnetzwerk, das Server mit Speichersystemen verbindet. Es ist getrennt vom normalen Datennetzwerk.

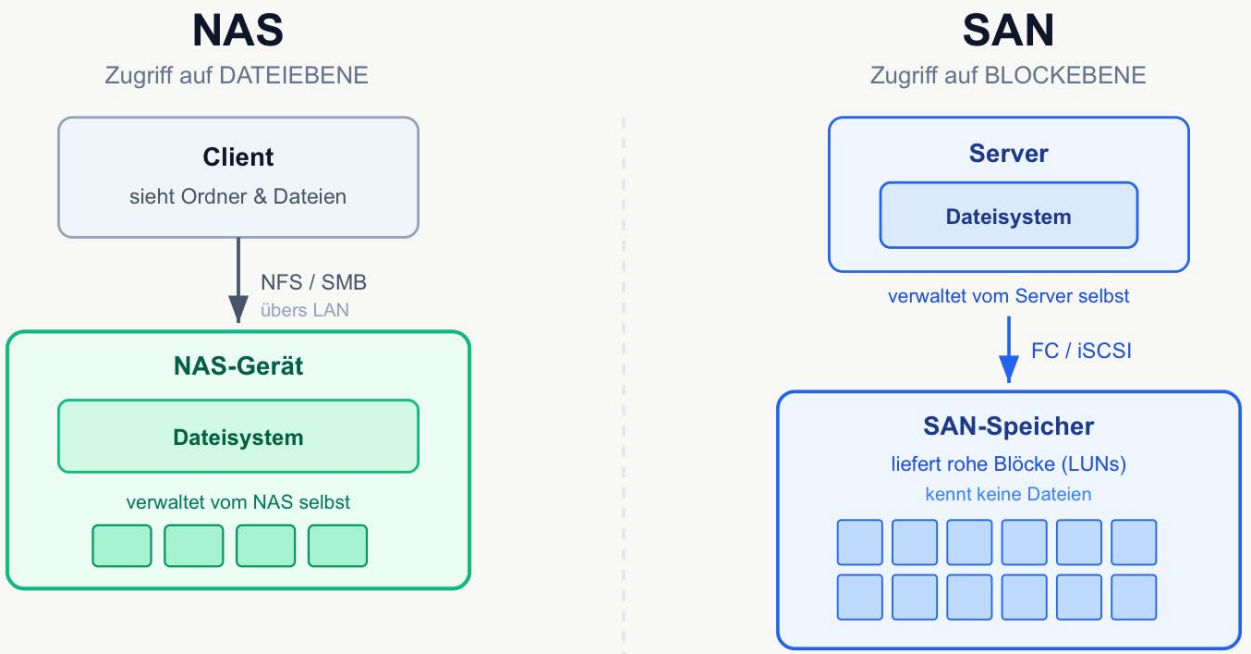
Im Gegensatz zu NAS arbeitet ein SAN auf Blockebene: Der Server sieht den Speicher nicht als Dateifreigabe, sondern als eigene Festplatte, die er selbst formatieren und verwalten kann (genau wie eine lokal angeschlossene Disk).

Dateiebene vs. Blockebene

Der wichtigste konzeptionelle Unterschied zwischen NAS und SAN liegt in der Zugriffsebene.

- Bei NAS greift der Client auf ein Dateisystem zu, das vom NAS-System selbst verwaltet wird. Der Client sieht Dateien und Ordner.
- Bei SAN greift der Server auf rohen Blockspeicher zu und verwaltet das Dateisystem selbst, genau wie bei einer lokalen Festplatte.

Dateiebene vs. Blockebene



Der entscheidende Unterschied

NAS liefert ein Dateisystem

Das Gerät verwaltet die Dateien.
Client bekommt Ordner & Dateien.

SAN liefert eine Festplatte

Der Server verwaltet das Dateisystem.
Wirkt wie eine lokale Platte.

Dateiebene vs. Blockebene

Praktische Konsequenzen

- Bei NAS können mehrere Clients gleichzeitig auf dieselben Dateien zugreifen, weil das NAS die Koordination übernimmt.
- Bei SAN-Speicher, der als virtuelle Festplatte eingebunden wird, kann in der Regel nur ein System gleichzeitig schreibend zugreifen (es sei denn, es kommt ein Cluster-Dateisystem zum Einsatz, das genau dieses Problem löst, etwa in Virtualisierungsclustern).

Prüfungsrelevante Einordnung



Für die Prüfung lässt sich die Auswahl anhand des Szenarios ableiten.

„Eine Abteilung benötigt einen zentralen Ordner für gemeinsame Dokumente, auf den mehrere Mitarbeiter zugreifen — das ist ein klassischer NAS-Einsatz mit SMB."

„Ein Virtualisierungscluster mit mehreren Hosts soll gemeinsamen Speicher für VM-Festplatten nutzen, mit hoher Performance und geringer Latenz — das ist ein SAN-Einsatz, je nach Budget mit Fibre Channel oder iSCSI."

„Ein einzelner Datenbankserver mit sehr hohem I/O-Bedarf, der keinen gemeinsamen Zugriff benötigt, ist mit DAS oder lokalem Storage gut bedient."

Prüfungsrelevante Einordnung



Die Prüfungslogik ist immer:

Wie viele Systeme brauchen Zugriff, auf welcher Ebene (Datei oder Block), und wie hoch sind die Performance-Anforderungen?

RAID

Einleitung

RAID (Redundant Array of Independent Disks) ist ein Verfahren, mehrere physische Festplatten zu einem logischen Laufwerk zusammenzufassen.

Die Ziele dabei sind je nach RAID-Level unterschiedlich gewichtet: höhere Performance, höhere Ausfallsicherheit durch Redundanz, oder eine Kombination aus beidem.

Einleitung

Wichtig für das Verständnis ist:

RAID schützt vor dem Ausfall einzelner Festplatten, aber es ist kein Ersatz für Backups, da es nicht vor versehentlichem Löschen, Ransomware oder dem Ausfall des gesamten Systems schützt.

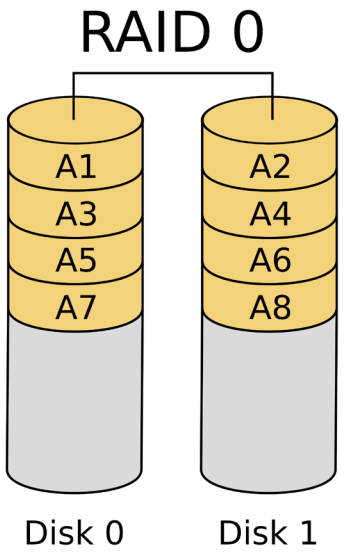
Für die AP2 müssen die gängigen RAID-Level 0, 1, 5, 6 und 10 erklärt, in Nutzkapazität berechnet und hinsichtlich ihrer Ausfallsicherheit begründet werden können.

RAID 0: Striping ohne Redundanz

RAID 0 verteilt Daten in Blöcken (sogenannten Stripes) gleichmäßig auf alle beteiligten Festplatten.

Das steigert die Performance erheblich, weil Lese- und Schreiboperationen parallel auf mehreren Platten erfolgen.

Die Nutzkapazität entspricht der Summe aller Festplatten: Bei vier Festplatten à 1 TB stehen 4 TB Nutzkapazität zur Verfügung.

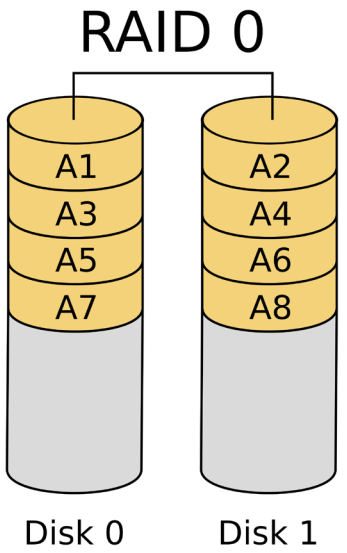


RAID 0: Striping ohne Redundanz

RAID 0 bietet keine Redundanz.

Fällt eine einzige Festplatte aus, sind die Daten des gesamten Arrays verloren, weil jede Datei über alle Platten verteilt ist.

RAID 0 wird daher nur eingesetzt, wo Performance entscheidend ist und Datenverlust verschmerzbar wäre (etwa bei temporären Daten oder Caches).

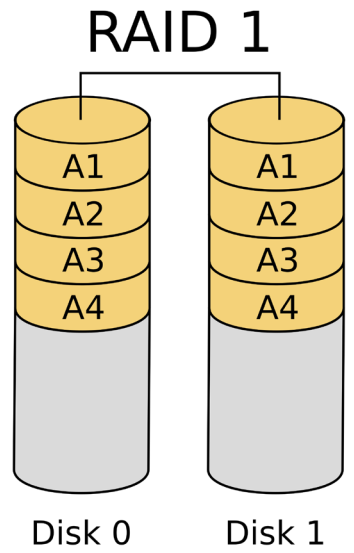


RAID 1: Spiegelung

RAID 1 spiegelt Daten identisch auf zwei (oder mehr) Festplatten.

Jede Platte enthält eine vollständige Kopie aller Daten.

Die Nutzkapazität entspricht der Kapazität einer einzelnen Festplatte, unabhängig davon, wie viele Platten gespiegelt werden: Bei zwei Festplatten à 1 TB stehen 1 TB Nutzkapazität zur Verfügung (die Hälfte der Rohkapazität).



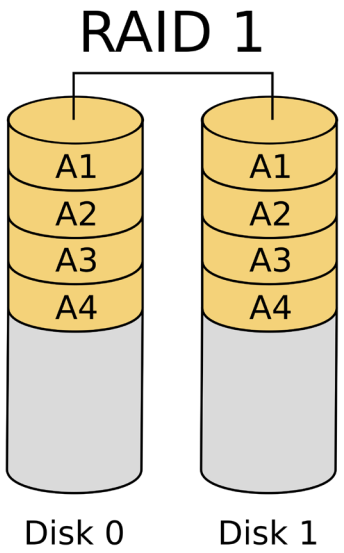
RAID 1: Spiegelung

Vorteil

Maximale Ausfallsicherheit bei minimaler Komplexität: Fällt eine Platte aus, läuft das System nahtlos mit der verbleibenden Kopie weiter. Auch die Leseperformance kann profitieren, da von beiden Platten gleichzeitig gelesen werden kann.

Nachteil

Geringe Effizienz, weil die Hälfte der Rohkapazität für Redundanz „verbraucht“ wird. RAID 1 wird häufig für Systemplatten eingesetzt, wo Ausfallsicherheit wichtiger ist als Kapazität.

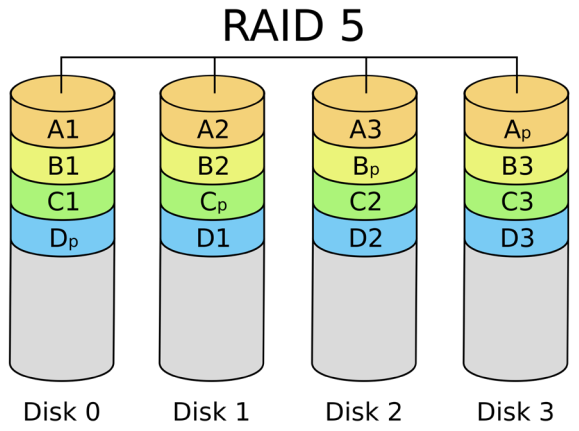


RAID 5: Striping mit verteilter Parität

RAID 5 kombiniert Striping mit einer Paritätsinformation, die über alle Platten verteilt gespeichert wird.

Bei n Festplatten entspricht die Kapazität einer Platte der Parität.

Die Nutzkapazität beträgt also (n-1) mal die Kapazität einer einzelnen Platte.

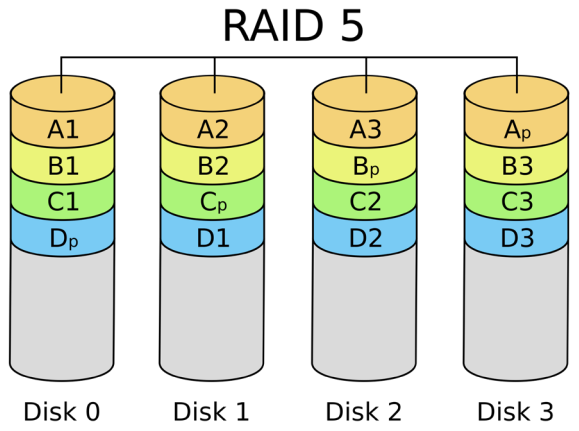


RAID 5: Striping mit verteilter Parität

Bei vier Festplatten à 1 TB stehen also 3 TB Nutzkapazität zur Verfügung.

Fällt eine Platte aus, können die fehlenden Daten aus den verbleibenden Platten und der Parität rekonstruiert werden.

Das System bleibt (eingeschränkt) funktionsfähig, bis die defekte Platte ersetzt und das Array wiederhergestellt ("rebuilt") wurde.



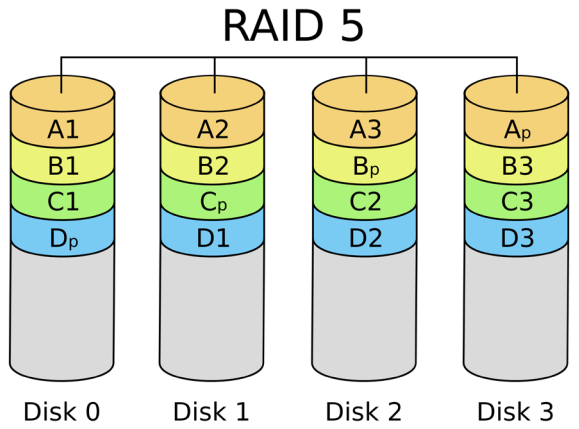
RAID 5: Striping mit verteilter Parität

Vorteil

Guter Kompromiss zwischen Kapazität, Performance und Ausfallsicherheit.

Nachteil

Während des Rebuilds ist die Performance stark reduziert, und ein zweiter Plattenausfall während dieser Zeit führt zum Totalverlust.



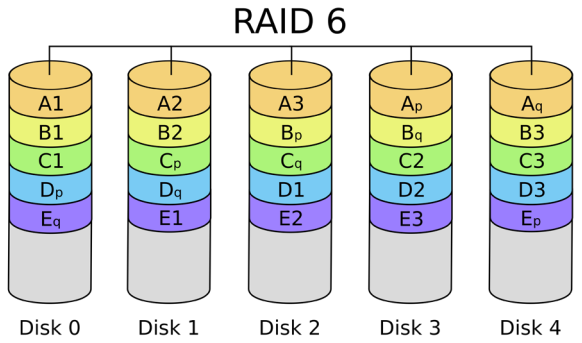
RAID 6

RAID 6 erweitert RAID 5 um eine zweite, unabhängige Paritäts-information.

Die Nutzkapazität beträgt (n-2) mal die Kapazität einer Platte (bei vier Platten à 1 TB also 2 TB).

RAID 6 verkraftet den gleichzeitigen Ausfall von zwei Festplatten, ohne Daten zu verlieren.

Das macht RAID 6 besonders für große Arrays mit vielen Platten interessant, wo die Wahrscheinlichkeit eines zweiten Ausfalls während eines Rebuilds steigt.



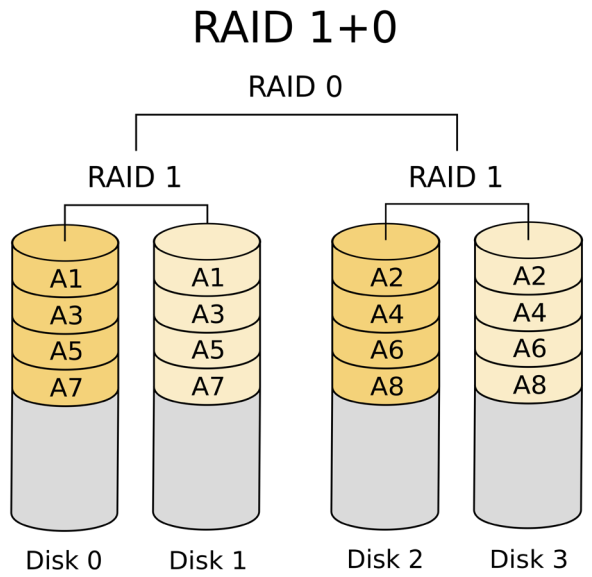
RAID 10

RAID 10 kombiniert Striping und Spiegelung.

Festplatten werden paarweise gespiegelt (RAID 1), und diese Paare werden dann gestriped (RAID 0).

Die Nutzkapazität beträgt die Hälfte der Gesamtkapazität (bei vier Platten à 1 TB also 2 TB).

RAID 10 bietet sowohl hohe Performance als auch hohe Ausfallsicherheit, ist aber in der Kapazitätseffizienz mit RAID 5 oder 6 vergleichbar bei deutlich höheren Kosten pro nutzbarem TB.



Prüfungsrelevante Einordnung



Für die Prüfung sind zwei Rechnungen entscheidend: die Nutzkapazität und die Anzahl tolerierbarer Plattenausfälle.

Bei n Platten mit Kapazität k gilt:

- RAID 0 hat Nutzkapazität n×k und verträgt 0 Ausfälle.
- RAID 1 hat Nutzkapazität k (unabhängig von n) und verträgt n-1 Ausfälle.
- RAID 5 hat Nutzkapazität (n-1)×k und verträgt 1 Ausfall.
- RAID 6 hat Nutzkapazität (n-2)×k und verträgt 2 Ausfälle.
- RAID 10 hat Nutzkapazität (n/2)×k und verträgt 1 Ausfall pro Spiegelpaar (im besten Fall mehrere gleichzeitig, im schlechtesten Fall führt der Ausfall beider Platten eines Paares zum Totalverlust).

Prüfungsrelevante Einordnung



Eine typische Prüfungsaufgabe gibt eine konkrete Anzahl und Größe von Festplatten vor und fragt nach Nutzkapazität und Ausfalltoleranz für verschiedene RAID-Level.

Wer die Formeln sicher anwenden kann, löst diese Aufgaben zuverlässig.

Tiered Storage, Caching-Konzepte

Performance vs. Kosten

Speicher unterscheidet sich nicht nur in Kapazität, sondern erheblich in Geschwindigkeit und Preis.

Schnelle Speichermedien wie SSDs oder NVMe-Speicher sind teuer pro Gigabyte, langsame Medien wie klassische Festplatten (HDDs) sind günstig, aber deutlich langsamer im Zugriff.

Performance vs. Kosten

Würde man die gesamte Datenmenge eines Unternehmens auf dem schnellsten verfügbaren Speicher vorhalten, wäre das wirtschaftlich kaum vertretbar.

Würde man alles auf günstigem, langsamem Speicher ablegen, würde die Performance leiden.

Tiered Storage und Caching sind zwei Konzepte, die dieses Spannungsfeld auflösen, indem sie Daten je nach Zugriffshäufigkeit auf unterschiedlich schnelle Speicherebenen verteilen.

Tiered Storage

Tiered Storage („gestufter Speicher“) bedeutet, dass innerhalb eines Speichersystems mehrere Speicherebenen mit unterschiedlicher Geschwindigkeit und unterschiedlichen Kosten existieren.

- Häufig verwendete Daten („heiße“ Daten) werden auf schnellem, teurem Speicher abgelegt, etwa NVMe-SSDs.
- Selten genutzte Daten („kalte“ Daten) wandern auf langsameren, günstigeren Speicher, etwa klassische HDDs oder sogar Bandlaufwerke für Archivzwecke.

Tiered Storage

Ein typisches dreistufiges Modell besteht aus

- Tier 1 (NVMe/SSD für aktive Daten)
- Tier 2 (SATA-HDDs für gelegentlich genutzte Daten)
- Tier 3 (Tape oder Cloud-Archiv für Langzeitaufbewahrung)

Die Daten bewegen sich automatisch zwischen den Ebenen, je nachdem, wie häufig auf sie zugegriffen wird.

Automatisches Tiering

Moderne Speichersysteme überwachen kontinuierlich, wie häufig auf bestimmte Datenblöcke zugegriffen wird, und verschieben sie automatisch zwischen den Tiers. Diesen Vorgang nennt man automatisches oder dynamisches Tiering.

Eine Datei, die monatelang nicht angefasst wurde, wird automatisch auf eine langsamere, günstigere Ebene verschoben. Wird plötzlich wieder häufig darauf zugegriffen, wandert sie zurück auf schnellen Speicher.

Automatisches Tiering

Für den Anwender ist dieser Vorgang transparent, denn er greift immer über denselben Pfad auf die Datei zu, unabhängig davon, auf welchem physischen Medium sie aktuell liegt.

Wirtschaftlicher Vorteil:
Ein Unternehmen kann große Datenmengen vorhalten, ohne dass alles auf teuerstem Speicher liegen muss, denn nur die tatsächlich aktiv genutzten Daten beanspruchen den schnellen, teuren Speicher.

Caching

Caching verfolgt ein ähnliches Ziel wie Tiered Storage, arbeitet aber anders.

Statt Daten dauerhaft zwischen Speicherebenen zu verschieben, wird bei Caching eine Kopie häufig genutzter Daten in einem schnellen Zwischenspeicher (dem Cache) vorgehalten, während das Original auf dem langsameren Hauptspeicher bleibt.

Greift ein System auf Daten zu, die sich bereits im Cache befinden ("Cache Hit"), erfolgt der Zugriff sehr schnell.

Caching

Befinden sich die Daten nicht im Cache ("Cache Miss"), müssen sie vom langsameren Speicher gelesen werden und werden dabei oft gleichzeitig in den Cache geladen, für den Fall, dass sie erneut benötigt werden.

Cache-Speicher ist typischerweise klein im Vergleich zum Gesamtspeicher, dafür aber sehr schnell (etwa RAM oder spezieller Flash-Speicher).

Lese-Cache vs. Schreib-Cache

Bei Caching unterscheidet man zwei Richtungen.

Ein Lese-Cache (Read Cache) hält Kopien häufig gelesener Daten vor, um wiederholte Lesezugriffe zu beschleunigen. Das Original bleibt unverändert auf dem Hauptspeicher.

Das ist unkritisch, weil im Fehlerfall einfach erneut vom Original gelesen werden kann.

Lese-Cache vs. Schreib-Cache

Bei Caching unterscheidet man zwei Richtungen.

Ein Schreib-Cache (Write Cache) ist komplexer: Schreibvorgänge werden zunächst nur im schnellen Cache vermerkt und erst später auf den eigentlichen Speicher übertragen ("Write-Back").

Das beschleunigt Schreibzugriffe erheblich, birgt aber ein Risiko: fällt das System aus, bevor die Daten aus dem Cache auf den Hauptspeicher geschrieben wurden, drohen Datenverluste.

Aus diesem Grund werden Schreib-Caches in professionellen Speichersystemen oft durch Batteriepufferung oder gespiegelte Cache-Module abgesichert.

Tiered Storage vs. Caching

Der konzeptionelle Unterschied lässt sich so zusammenfassen:

- Bei Tiered Storage existiert jede Datei nur einmal, aber auf wechselnden Speicherebenen, abhängig von der Zugriffshäufigkeit.
- Bei Caching existiert eine zusätzliche, temporäre Kopie häufig genutzter Daten auf schnellerem Medium, während das Original an seinem Platz bleibt.

Prüfungsrelevante Einordnung



Beide Konzepte verfolgen dasselbe wirtschaftliche Ziel: die Performance schneller, teurer Speichermedien nutzen, ohne die gesamte Datenmenge darauf vorhalten zu müssen.

In der AP2 wird meist die Begründung erwartet, warum ein Unternehmen mit großen, aber unterschiedlich häufig genutzten Datenmengen von Tiering oder Caching profitiert, etwa ein Unternehmen mit großem Archivbestand, bei dem nur ein kleiner Teil der Daten aktiv bearbeitet wird, während der Großteil selten abgerufen wird.

Backup-Strategien

Drei Strategien, ein Ziel

Backups sichern den Zustand von Daten zu bestimmten Zeitpunkten, damit sie im Fehlerfall wiederherstellbar sind.

Die Frage ist jedoch nicht nur, ob gesichert wird, sondern wie?

Dein tägliches Vollbackup aller Daten ist oft weder zeitlich noch speichermäßig praktikabel.

Drei Strategien, ein Ziel

Drei Strategien haben sich etabliert:

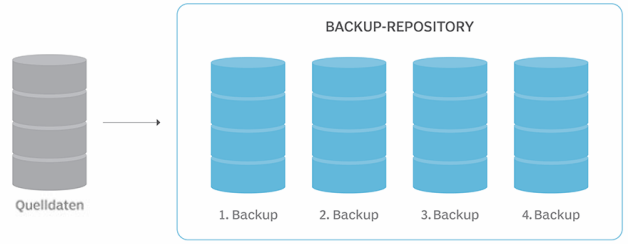
- Vollbackup
- Inkrementelles Backup
- Differenzielles Backup

Sie unterscheiden sich darin, welche Daten bei jedem Sicherungslauf erfasst werden.

Das hat direkte Auswirkungen auf Speicherbedarf, Sicherungsdauer und vor allem auf die Wiederherstellungszeit im Notfall.

Vollbackup (Full Backup)

Ein Vollbackup sichert bei jedem Durchlauf den gesamten Datenbestand, und zwar unabhängig davon, ob sich seit dem letzten Backup etwas geändert hat oder nicht.



Der Vorteil ist die Einfachheit der Wiederherstellung.

Im Fehlerfall wird einfach das letzte Vollbackup eingespielt. Es gibt keine Abhängigkeiten und keine Verkettung mehrerer Sicherungen.

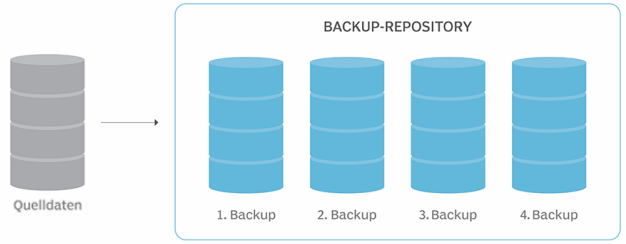
Vollbackup (Full Backup)

Der Nachteil ist der enorme Speicherbedarf und die Dauer, bis eine Sicherung erstellt ist.

Jeder Durchlauf benötigt so viel Platz wie der gesamte Datenbestand, auch wenn sich nur wenige Dateien geändert haben.

Tägliche Vollbackups bei großen Datenmengen sind daher oft unpraktikabel.

In der Praxis werden Vollbackups meist in größeren Abständen durchgeführt (etwa wöchentlich) und mit anderen Strategien kombiniert.

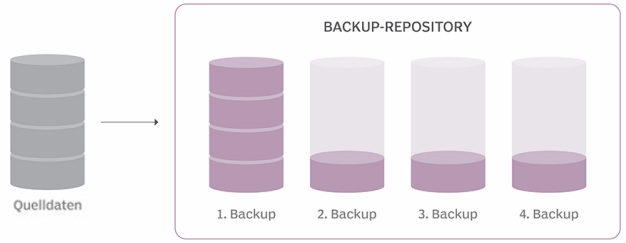


Inkrementelles Backup

Ein inkrementelles Backup sichert nur die Änderungen, die seit dem letzten Backup (egal ob Vollbackup oder differenzielles Backup) vorgenommen wurden.

Jedes inkrementelle Backup bezieht sich also auf das unmittelbar vorherige Backup, nicht auf das ursprüngliche Vollbackup.

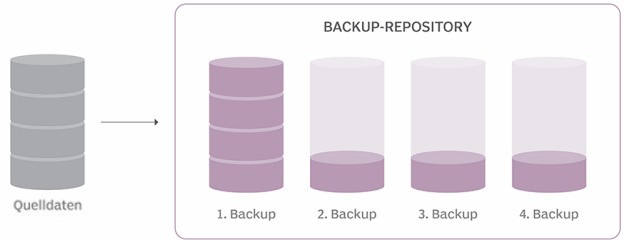
Das macht inkrementelle Backups sehr klein und schnell, weil jeweils nur die Änderungen eines kurzen Zeitraums erfasst werden.



Inkrementelles Backup

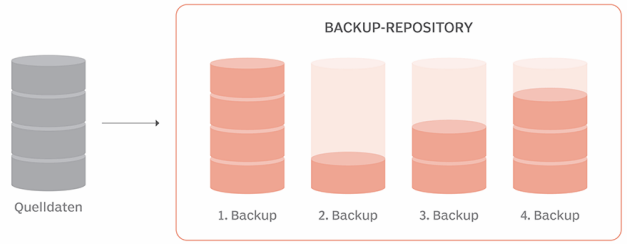
Der Nachteil zeigt sich bei der Wiederherstellung: Es wird das letzte Vollbackup benötigt, plus alle inkrementellen Backups in der richtigen Reihenfolge bis zum gewünschten Wiederherstellungspunkt.

Bei täglichen inkrementellen Backups über eine Woche bedeutet das im schlimmsten Fall: ein Vollbackup plus sechs inkrementelle Backups, die alle nacheinander eingespielt werden müssen.



Differenzielles Backup

Ein differenzielles Backup sichert alle Änderungen, die seit dem letzten Vollbackup vorgenommen wurden, und zwar unabhängig davon, wie viele differenzielle Backups dazwischen schon gelaufen sind.



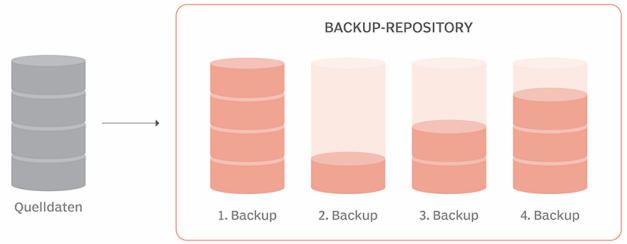
Jedes differenzielle Backup bezieht sich also immer auf dasselbe Vollbackup als Ausgangspunkt.

Differenzielles Backup

Differenzielle Backups werden mit der Zeit immer größer, weil sie alle Änderungen seit dem Vollbackup kumulativ enthalten.

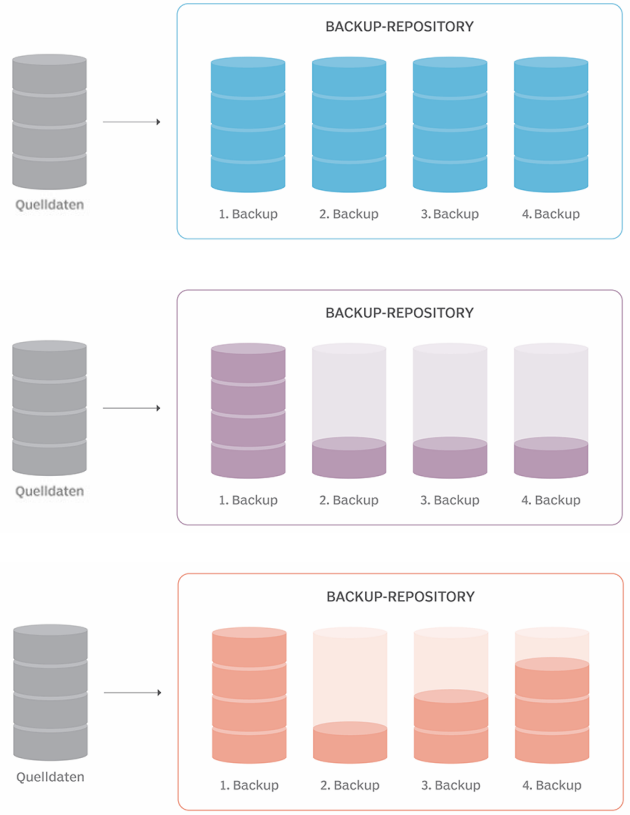
Für die Wiederherstellung werden genau zwei Sicherungen benötigt: das letzte Vollbackup plus das letzte differenzielle Backup.

Das macht die Wiederherstellung übersichtlich und vergleichsweise schnell, auch wenn mehrere Tage seit dem Vollbackup vergangen sind.



Speicherbedarf

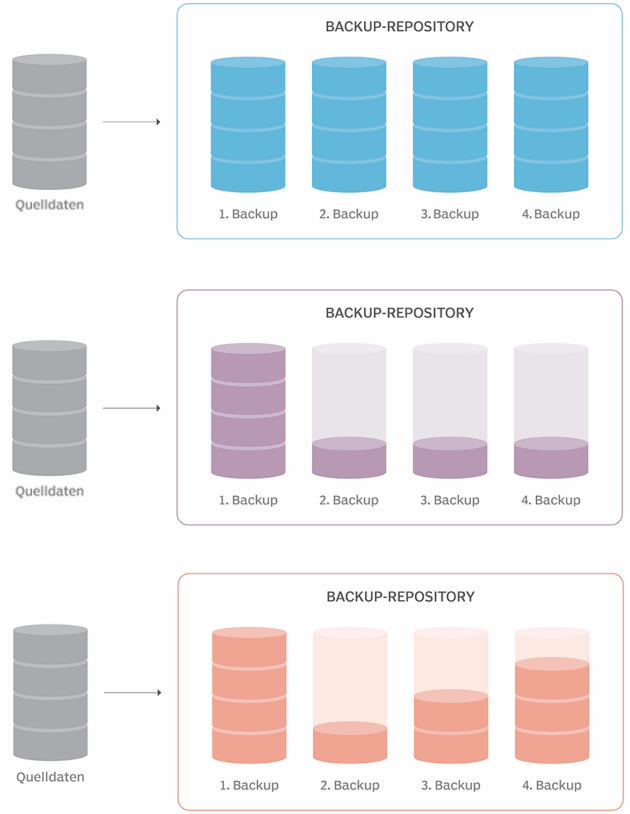
- **Vollbackups** benötigen am meisten Platz, da jeder Durchlauf die komplette Datenmenge umfasst.
- **Inkrementelle Backups** sind am sparsamsten, da jeweils nur die Änderungen eines kurzen Zeitraums gesichert werden.
- **Differenzielle Backups** liegen im Mittelfeld und wachsen mit der Zeit seit dem letzten Vollbackup.



Sicherungsdauer

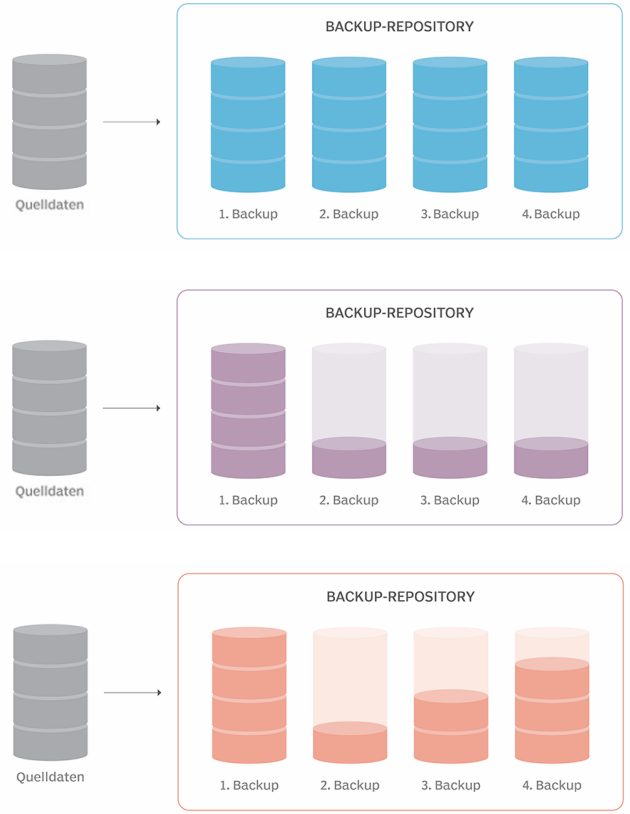
- Vollbackups dauern am längsten
- Inkrementelle Backups gehen am schnellsten
- Differenzielle Backups liegen im Mittelfeld

Das macht inkrementelle Backups attraktiv für häufige Sicherungsläufe, die das Tagesgeschäft nicht beeinträchtigen sollen.



Wiederherstellungszeit

- Ein Vollbackup ist am schnellsten wiederherzustellen, da nur eine einzige Sicherung eingespielt werden muss.
- Ein inkrementelles Backup benötigt potenziell viele Schritte, denn es müssen das Vollbackup plus jedes einzelne inkrementelle Backup in der richtigen Reihenfolge zurück gespielt werden.
- Ein differenzielles Backup benötigt zwei Schritte (Vollbackup plus letztes differenzielles Backup).



14.09.2026

Ende